



ISS Projekt 2020 / 21

Autor: Yehor Pohrebniak(xpohre00)

Datum: 23.12.2020

Řešení

Řešení jsem implementoval v pythonu. Použil jsem knihovny **numpy**, **scipy**, **matplotlib**, **random**. Všechna audia jsem nahrál při pomoci smartphonu.

Zadání

1.


Název	Délka v [s]	Délka ve vzorcích
maskon_tone.wav	1.36	21760
maskoff_tone.wav	1.44	23040

2.


Název	Délka v [s]	Délka ve vzorcích
maskon_sentence.wav	4.4	70400
maskoff_sentence.wav	4.42	70720

3. Pro vytvoření rámců jsem zahodil poslední 100 ramec pro každý signál. Seznamy `frameMaskOffTone` a `frameMaskOnTone` obsahují 99 rámců z signálů **maskoff_ton.wav** a **maskon_ton.wav**. Frekvence každého signálu je 16000 Hz, což znamená, že signál delkou v 1s bude mít velikost 16000 vzorců. Pro 1 ramec délkou 20 ms jsem našel velikost ve vzorcích při pomocí vztahu $1s/20ms = 16000/x$, $x \Rightarrow 320$, délka jednoho ramcu = 320 vzorců.

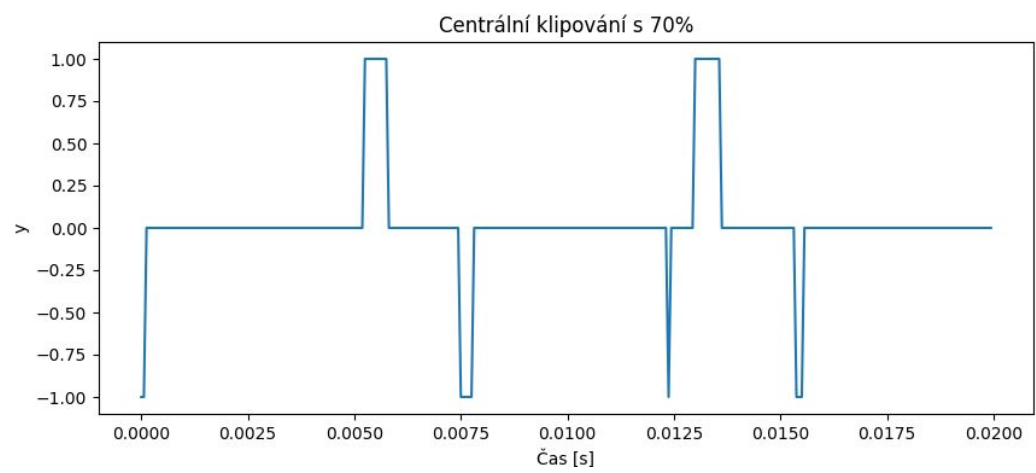
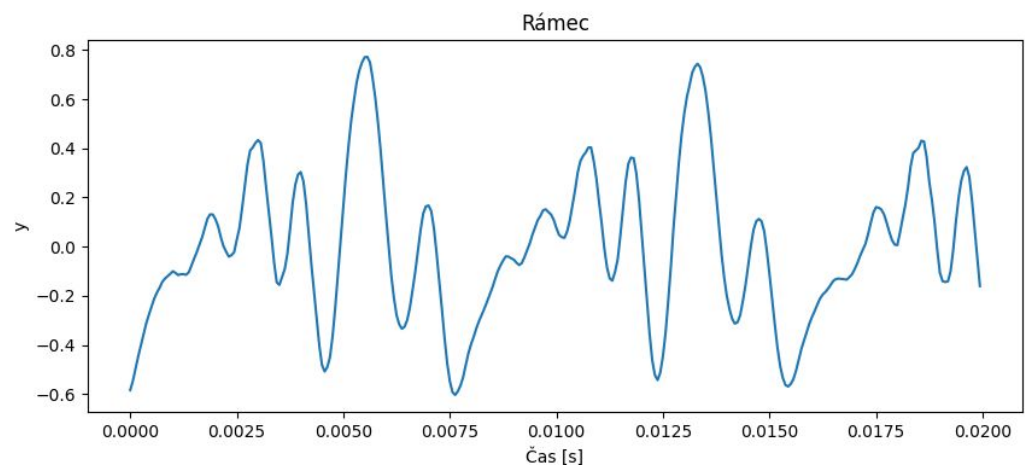
Část signálu maskoff_tone.wav o délce 20ms(1 ramec)


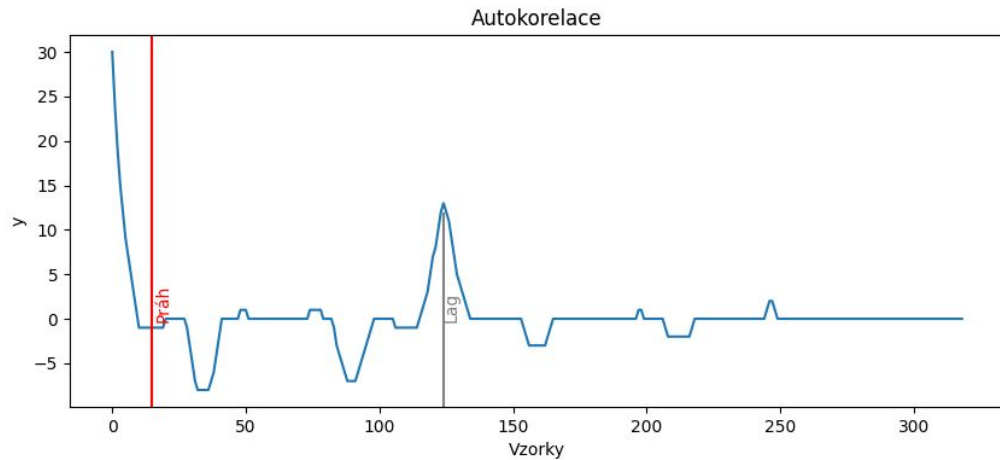


Část signálu maskon_tone.wav o délce 20ms(1 ramec)



4.





Střední hodnota:

základní frekvence rámců bez roušky = 269.27

základní frekvence rámců s rouškou = 252.95

Rozptyl:

základní frekvence rámců bez roušky = 102856.40

základní frekvence rámců s rouškou = 98317.72



Odpověď na otázku: Zmenšení základní frekvence, by se dalo zmenšení velikosti f_0 pry chybě ± 1 . Protože $f_0 = F_s/\text{lag}$, což kvůli většímu F_s bude tvořit velký rozdíl mezi f_0

5. Funkci DFT jsem implementoval v Pythonu (funkce se jmenuje dft).


```
def dft(s):
    s = np.asarray(s, dtype=float)
    N = s.shape[0]
    n = np.arange(N)
    k = n.reshape((N, 1))
    M = np.exp(-2j * np.pi * k * n/N)
    return np.dot(M, s)
```

Kontrola probíhá s funkcí `np.fft.fft()` (Náhodně se vybere ramec, který bude transformován dvěma funkcemi a výsledky se pak porovnají). DFT pro signaly provádím při pomoci `np.fft.fft()`, protože moje funkce je pomalejší a trvá to nějaký čas, než na DFT převede 1024 x 99 vzorků. Pro funkci `dft` jsem použil následující vzorec

$$x[k] = \sum_{n=0}^{N-1} x[n] e^{\frac{-j2\pi kn}{N}}$$



6. $H(e^{j\omega}) = |DFT(\text{MaskOn})| / |DFT(\text{MaskOff})|$




Je to FIR filtr s horní propustí

7. Funkci IDFT jsem implementoval v Pythonu(funkce jmenuje se idft).


```
def idft(s):
    s = np.asarray(s, dtype=float)
    N = s.shape[0]
    n = np.arange(N)
    k = n.reshape((N, 1))
    M = np.exp(2j * np.pi * k * n/N)
    return np.dot(M, s)/N
```


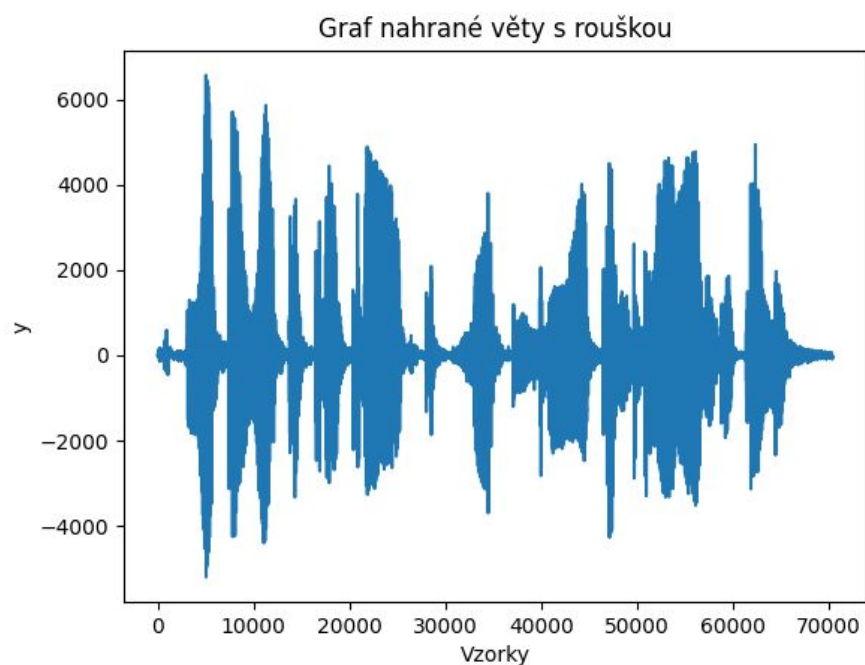
Kontrola probíhá s funkcí `np.fft.ifft()`. Použil jsem následující vzorec pro implementaci IDFT:

$$x(n) = \frac{1}{N} \sum_{k=0}^{N-1} X(k) e^{j \frac{2\pi k n}{N}}$$



8. Filtraci signálu jsem provedl při pomoci funkcí **signal.lfilter**. Pro vytváření nahrávek **sim_maskon_tone.wav** a **sim_maskon_sentence.wav** jsem použil funkci **wavfile.write** a okomentoval jsem 2 řádky v kódu, aby při spuštění se nevytvořili opět soubory. Signály jsem převedl na int16 pro soubory wav.





Signály s rouškou a simulovanou rouškou jsou mezi sebou podobný. Nejvíce se věty podobají na začátku a na konci a trochu se liší ve středu v intervalech(30000 - 60000) v signálu s rouškou a (20000 - 60000) v signálu s simulovanou rouškou.

9. **Závěr:** Moje řešení funguje správně, jenom trochu pomalu, kvůli tomu, že jsem nenašel lepší způsob jak implementovat autokorelaci(trva to nějakých 7 - 8 sekund). Taky nejsem si jistý, že moje nahrávky mají stejný tón i když jsem několikrát nahrával.

11. Vybral jsem Hammingovou okenkovou funkci(`numpy.hamming()`).

$$w(n) = 0.54 - 0.46\cos\left(\frac{2\pi n}{M-1}\right) \quad 0 \leq n \leq M-1$$

Vytvořil jsem pole obsahující 1024 prvky a provedl jsem násobení ramce před použitím funkce `np.fft.fft()`.

